

LLM 3-Days Report.

Small Language Model -

- parametrlar 1 mln dan bir necha mlrd
- model hajmi kichik
- ishlatish juda tez
- RAM talabi kam
- GPU ko'pincha shart emas
- telefonda ishlatish - Ha
- narxi arzon

Large Language Model -

- parametrlar 50 yuzlab mlrd.
- model hajmi juda katta
- ishlatish sekinroq
- RAM talabi juda ko'p
- GPU talabi - kuchlari kerak
- telefonda odatda ishlanmaydi
- narxi qimmat

SLM ~~AS~~ Ilatilishi.

- Telefon Assistant
- offline chatbot
- Embedded device
- Robot
- IoT
- Smart watch
- Edge AI

LLM Qillanvosh

chat GPT

Cursor

AI Coding

Research

AI Agent

Medical AI

Scientific Assistant

Enterprise AI

Gemini, Grok, Llama

IOT - bu internet orqali bir-biri bilan boglangan aqlli qurilmalar jamoasi.

Embeddings - bu matn, sht, rasmlar yoki boshqa ma'lumotlarni kompyuter tushuna oladigan sonlar (vektor) ko'rinishida o'tkazish usuli.

"Mashina" $\Rightarrow [-1.12, 0.43, -0.62, 2.10, \dots]$

Transformer NN

Em-Embedding - soxlarni sonlarga o'tkazish

Attention - qaysi sht yuqumligini aniqlaydi

Transformer - embedding va attention yordamida matnni tushunadigan qadimiy usul sarakat.