

Savollarga Javoblar

(Assosiy savollar)

① LM va LLM sifatida qanday farq bor?

LM - har qanday sh modelga beriladigan umumiy nom.
LLM - juda katta parametrlar bilan oqotilgan sh model.

② LLM va SML (small) sifatida qanday farq bor?

SML - kichik parametrlar bilan ishlaydi va kam xotira talab qiladi.

LLM - esa katta parametrlar bilan ko'proq bilim va reasoning qobiliyatiga ega.

SML odatda telefon yoki edge qurilmalarida, LLM esa server va cloud muhitida ishlatiladi.

③ Better Lesson nima (Rich Sutton)
Better Lesson shuni talab qiladi
AI muhojira qilida yozilgan qadimiy dalardan ko'ra ko'proq ma'lumot va compute. Tardix davomida yangi umumiy algoritmlar va ko'p hisoblash resurslari eng yaxshi natija bergan.

④ Claude, ChatGPT va Gemini
qanday model?
Ularning barchasi "Generative
Large Language Model (LLM)" hisoblanadi.
Bu modellarni ma'nada yaratish, savollarga
javob berish, kod yozish va
reasoning sa'yifalarini bajaradilar.

⑤ Claude, ChatGPT, Gemini oilalariga
kiritilgan asosiy modellarni.
ChatGPT: GPT-3.5, GPT-4, GPT-4o, GPT-5
Claude: Claude 3 Haiku, Sonnet, Opus.
Gemini: Gemini Nano, Pro va Ultra.

⑥ BPE (Byte Pair Encoding) nima?
BPE - matnni kichik bo'laklarga
ayratish algoritmi. U eng ko'p
uchraydigan belgilar yoki so'z
qismlarini bo'lashtirib yangi token
hosil qiladi. Bu usul lugat
hajmini kamaytiradi va modelning
normalum so'zlarini ham tushunish
yordam beradi.

⑦ Tokenizatsiya nima va u nima
uchun kerak?

Tokenizatsiya - matnni model qayta
ishlay oladigan tokenlarga ayratish
jarayoni. LLM matnni belgilar, so'zlar
yoki belgilarga bo'lib qayta yaratadi.

⑧ Trainingni boshlatishdan oldin nimani
buni hisobga olish kerak?
Dataset sifatini na hajmi, model
suzulturasi, GPU soni, memory va
compute resurslari aniqlanadi.
shuningdek learning rate, batch size,
sequence length kabi hyperparameter
tanlanadi.

⑨ Model parametrlari soni qanday
hisoblanadi?

parametrlar modeldagi barcha
weight va bias o'zgaruvchilarning
umumiy sonidir. Hozir bor
linear layer, embedding va
boshqa qatlamlarning para-
metrlari qo'shib chiqiladi.
Masalan, 4B model taxminan
4 mlrd parametrga ega bo'ladi.

⑩ Model uchun kerakli xotira
(memory) qanday hisoblanadi?
Xotira hajmi parametrlar
soni va ularning formatiga
bog'liq. Oddiy formula:

Memory = parametrlar * Bytes
Ushbu FP16 formatida har bir para-
metr 2 bayt joy egallaydi, BF16
ham odatda 2 bayt ishlatiladi.

⑫ Trade-off nima degand
Trade-off - bir narsani yaxshi-
lash boshqaga boshqa narsadan
veya lechiq. Masalan, modelni
katta lashtirish sofatni oshiradi
fikir compute va memory talabini
ham oshiradi. AI tajribalarini loyi-
halarida oleyarli har doim
trade-off mavjud bo'ladi.

⑬ Frontier model nima?
Frontier model - ma'lum bir da-
rja eng ilgar va eng kuchi li
modeli. Bunday modellari odatda
eng katta compute va eng katta
datasetlarda oqitiladi. Ular
yangi benchmarklarda yuqori natija-
lar ko'rsatadi.

⑭ Emergent Ability (paydo bo'lishi
qobiliyat) nima?
Emergent ability - model kattalar-
gani sari oldin mavjud bo'lmagan
yangi qobiliyatlarining paydo
bo'lishidir. Masalan reasoning
murakkab matematika yoki kod
yozish qobiliyati bu qobiliyatlari
kichik modellarda bo'lmaganligi

14) Scaling Law nima?
Scaling law chuni ko'satadiki,
model parametrlari, dataset va
compute oshgani sari model
sifati ham yaxshilashadi. Ammo
osish chekedi emas, ma'lum nuqta
dan keyin boyda sekinlashadi.
Zamonaviy LLM lar aynan shu
qonuniyat asosida rivojlanmoqda.

15) Chinchilla qoidasi nima? angliya
chinchilla qoidasi parametrlar va
training tokenlari o'rtasida
optimal nisbat bo'lishi kerak
degani aytadi. Yuda katta
modelni kam ma'lumot bilan
o'qitish samarali emas. Koproz
token bin o'qitilsan kuchliroq
model bilan kattaroq modeldan
ham yaxshi iqlashi mumkin.

16) Alignment nima?
Alignment - modelning javoblari
inson qadriyatli va foydali
mulozimatchilik jarayoni. Bu sa-
rarli yoki notog'ri javoblarni
kamaytirish yordam beradi.
SFT va RLHF alignment asosiy
usullari hisoblanadi.

17) SFT (Supervised Fine-Tuning) nima?

SFT - tayyor modelni saqlash-javob
juz'atliklari yordamida qayta oqitish
jariyoni. Model to'g'ri javob namo-
nalardan o'rganadi. Bu bosqich
modelni aniq vazifalar uchun mos-

18) RLHF nima?

RLHF - reinforcement learning from
human feedback, inson baholari
asosida modelni yaxshilash usuli.
Bu model javoblarining foydali-
ligini raqamli baholashni oshiradi.

19) Transformer arxitekturasini nima
uchun muhim?

- Transformer samonardiy LLM luga
asosiy arxitektura hisoblanadi.
U Self-Attention yordamida matnning
birlamchi bog'lanishlarini tushunganda
GPT, Claude, Llama model/Transformer

20) FLOP nima?

FLOP - floating point operation
- bitta susmechi nuqtali matnna
fikr anal. Model training va inference
nafaqat FLOP lar soni bilan baholash
FLOP qancha shuncha murakkab bo'ladi.

(21) MPU (Model FLOPS hisoblashi) nima?

MPU - GPU hisoblash quvvatidan model ganchalik samarali foydalana olinganini ko'rsatadi. Yuzani MPU trainingning samarali ketayotganini bildiradi. Amalda MPU odatda 40-50% atroflarda bo'ladi.

(22) BF16, FP16, va FP32 o'rtasidagi farq nima?

Ular sonlarni saqlash aniqdigi va xotira hajmi bilan farqlanadi. FP32 eng aniq, lekin ko'proq memory memory ishlatadi. BF16 va FP16 kamroq talab qiladi va trainingni tezlashtiradi.

(23) AdamW optimiser nima uchun

LLM trainingda standart hisoblanadi. AdamW tez konvergensiya qiladi va trainingni barqarorlashtiradi. - weight Decay yordamida overfittingni kamaytiradi. - Shu sababli u hamma joyda Transformer modellari uchun standart optimiser hisoblanadi.

24) Xavier Initialization nima uchun kerak?

Xavier Initialization nima uchun kerak? - boshlang'ich weightlarni to'g'ri taqsimlash usulidir. U grade of learning juda kichik yoki juda katta bo'lgan ketishini oldini oladi. Natijada model trainingni barer qiladi.

25) Activation checkpointing nima? Activation checkpointing - training jarayonida memoryni tejash usuli. Barcha activationlar saqlanmaydi, kerak bo'lganda ulare qayta hisoblanadi. Bu usul katta LLM larni kichikroq GPU larda o'qitishga yordam beradi.