

6-Dars. Saoud Jacob 2-qism.

① LLM model Arxitekturasini tushunib bering.

LLM (large language model) -
bitta xujumdagi matnlar asosida
soqitilgan va matnni foshlash
generatsiya qilish, tushunish
saxobot - saxobot va maslahat
kabi vazifalarni bajarish
qiluvchi NN model.

Bular Transformer arxitektura
asosida quriladi.

- matn tokenlarga ajratiladi
- tokenlar embedding va vektorlarga ay-
lanadi
- positional information orqali token
larining tartibi hisobga olinadi
- bir nechta transformer layerlardan
o'tadi.
- Attention konsepti o'rganiladi.
- FFN representatsiya qayta shakl
o'tirishda ishtirok etadi.
- model keyingi tokenni prediction

② Encoding va Embeddings farqi?

Encoding - ma'lumotni model yoki
kompyuter ishlatish uchun
shaklga o'tkazish jarayoni.

Embedding - token yoki obyektni
real sonlardan fashkil topgan
yoki (dense) vektorga aylantirish

③ Trickle off: nima?

Trickle-off - bir xususiyatni yaxshi
lash natijasida boshqa xususiyat
dan ma'lum darajada vay hadda
ga to'g'ri kelgan xolat

④ Qanday xolatda model toxtab qoladi? Buyulib qoladi?

- Context window tugash
- maximum generation length
- EOS (end of sequence) token
- Repetition
- Resource yetishmasligi
- Training instability

⑤ Attention va Attention layer farqlari?

Attention - tokenlar o'rtasidagi
bog'lanishni hisoblash mexanizmi

Attention Layer - shu Attentionni
mexanizmini o'z ichiga olgan qatlam
ni ko'rsatuvchi

⑥ Serial va parallel qanday farq bor?

Serial - operatsiyalar ketma-ket
bajiriladi

Parallel - bir nechta operatsiya
bir vaqtning o'rtida bajariladi

Serial

A → B → C → D

Parallel

→ A →
Input → B → output
→ C →

⑦ Nima uchun RMSE yaxshi?

Bu model xatoligini o'lchaydigan yaxshi
tamoni bo'lsa xatolarga ko'proq
penalty beradi.

⑧ Nima uchun Relu ishlatilgan?

Relu da $x < 0 \rightarrow 0$ bo'ladigan natijalar
ayrim neuronlar ushbu rang
aktivatsiya bermasligi mumkin.

Bu holat o'ylang Relu deb atalgan
tamondagi LL klavida

Gelu / Silu / Swish / Smo Glu
lar ishlatiladi. Bular o'zaro
fonlar ko'pcha yaxshiroq
performance beradi.

⑨ MHA va MQA nima?

MHA - multi head Attention

Q, K, V proksadalariga esa

Har bir head turli xil relationship
organishni mumkin.

MQA - multi-query - Attention

MQA da barcha query headlar
alohida bo'ladi, lekin K va V

umimiy bo'ladi. Bu KV cache

memoriyani saqlashda kamaytirish
va inference ni tezlashtirish
mumkin.

10) MQA vs GQA?

MQA - multi query attention
GQA - grouped query attention
Bu MHA va MQA sifatidagi
kompromis yaini bir nechta
query head bitta K/V head
bilan group qiladi.

MHA - maksimal head independence
MQA - maksimal memory efficiency
GQA - quality va efficiency balans

11) Distributed Representation nima?

Bu - obyekt yoki tokenning ma'nosi
sitta elementda emas, balki
ko'plab o'lchamlardan tashkil topgan
vektor ko'plab jinsdamlangan holda
ifodalanishi.

LM larida tokenlar o'zaro
distributed representation orqali
sense vector sifatida ifodalanadi.

12) Reasoning nima?

Reasoning - berilgan ma'lumot
lardan foydalanib, mantiqiy xulosa
chiqarish va muvohabat masala
lari orqali nechta bog'langan
judamlar orqali hal qilish
qobiliyati.