

3-Dava LLM 2-oy Report.

1-Savol: Pre-training va post training farqi nima? Hare bor bosqichda model da nima o'rganadi? Qaysi kuni kiproq data tarlab qiladi?

pre-training - model juda katta hajmdagi umumiy data bilan o'qitiladi. Model fil, bilim va umumiy patternlarni o'rganadi.

post training - tayyor model maxsus data orqali javab berish ushbu, topshiriqga moslashish va xatoliklarni yaxshilaydi.

2-savol: Common Crawl ni to'g'ridan-to'g'ri training uchun ishlatib bo'lmaymi?

Common crawl tozalash → filtrlash → deduplication → sifatli fiksatsiya lardan song qolnadi.

Common Crawl ni to'g'ridan-to'g'ri trainingga ishlatib bo'lmaydi.

- kerakli va sifatli kontent ko'p
- Spam, baliqana va takroriy sahifa
- data formati va sifatli ma'lumot
- tol emas.

LLM loyhasida. gitga ichki
nima qilish kerak va nega?

bu yerda gitga chiqarib
kerak bo'lmagan barcha
narsa yoziladi. Masalan:

- API keylar,
- parollar
- user / userlar
- katta datasetlar
- training loglar
- katta model fayllari (checkpoint)
- jupyterning raqibchalik fayllari

API kalit yoki token repository
qilish qo'sha nima qiladi?

- Tokenni o'rindi / delete qilaman
- yangi api key yarataman
- git historydan iski keyni olib

Pre training uchun nega CPU emas

GPU salohiyatida? Nima uchun GPU

LLM da kerak? Nima uchun vs cost

GPU - LLM training juda ko'p

hisa - hisob hisoblarini bajaradi

LLM model lab parametriga qo'sha

qalad, CPU b-m training juda sekin va
qimmatga tushad.

VS Code - kod yozish / Colab = GPU shi.

Data mixture nima va nima bo'lsa
dataset yetarli emas?

Bu modelni oqitishda faqat xal datasetni
malumotlar yaratish

Data mixture = faqat data + faqat kodlar
malar, + kuchliroq universalroq model.

Deduplication nima? va nima trainingda
shin qilmadi?

Training datasetdagi takroriy qimmat
malumotlarni olib tashlash jarayoni

Deduplication - takroriy datani
olib tashlash - toza va samarali
training data.

Nima kichikroq data avtomatik
ravishda yaxshiroq modelni yaratadimi?

chunki data miqdoridan ko'ra

sifati muhimroq.

Sifatli hilda - bu va toza

data modelni yaxshiroq oqitish
digan qalad.

MIT litsensiyali datages yaratish model
tuzatish, shundan uchin talab qoldi?
Bunday holatda shunday yaratish
organizatsiya, kommersial boydalar
nashr mumkin Copyright notice
sarglash kerak

Codingga yonaltirilgan LL uchun
data mixture tuzish va har bir
bosqichni tashlash.

Source code	- 50X
code documentation	- 15X
code + explanation	- 15X
bug fixing / code repair	- 10X
math / reasoning	- 5X
general text	- 5X

Data setning 80% ingliz tilidagi
mahsulot esa shu tilidagi boyda
tanimechilar uchun shu tilidagi
shu tilidagi data ulushini
oshiraman, shu bilan shu tilidagi
dastlarni oshiraman

pre training data va post training
(SFT / preference) data qanday farq
qiladi?

Pre training data - shu tilidagi

shuni sugatadi
SPT - qanday jareab berishni sugatadi
preference = qaysi jareab yaxshiroq
ekani sugatadi.

Metrika **reshiga** aynan data yigirish
sahib bo'lganini qanday rehatlaysoz
controlled experiment (A/B) test sugatadi
baseline eski data bilan model
natijasini solishtirib, barcha datani
yigirib, boshqa barcha para-
metrlarni bo'xal goldaman

Data **tasvirlashni** **toxtatib**, **trainingsni**
boshlash **reagtion** **qanday** **belgilaysoz**
validation natijasi yaxshilannay
og'lsa yoki juda ko'chik yaxshila-
nish bersa - tasvirlashni toxtata-
man

Nima **uchun** **bo'x** **shunchaki** **katta**
hazindagi **datasetni** **yuklab** **olib**,
davhol **LLM** **modellni** **train** **qila**
olmagan

Katta **datasetda** **sifatsoz** **dupla**
cate **ra** **keraksoz** **data** **bo'lsa**
munim. **Real** **and** **tasvirlash** **kerak**
Data **sifati** **ra** **olma** - **tallogi** **haz**
dan **munim**.