

LLM 2-oy 5-Days Report

PIT - bu shaxsiy ma'lumotlarni
maska qilish y'ni yashirish.

BPE - byte pair encoding.

Kisoy ushi modeldagi bilgi, so'z no
kichik subword larga ajratadi
top usunlikdagi so'zni tisray amalga
shirish uchun re embeddingni table
hajmini kamaytirish u-n.

BPE Merge Rules - eng ko'p takror
lanadigan token yoki bilgolar
jiftligoni birlashtirish re u/p
ketmo - ket tartibini saqlaydigan
qoidalar topiladi.

Vocabulary Size Trade-off.

Kichik vocabulary model embedding
ni ko'rsatadi lekin compute
sarajaratoni shiradi, katta vocab
re aksincha sequence usunligini qisqartiradi.

Special Tokens - matn chegaralarni
ko'rsatish, $\langle eos \rangle$, $\langle bos \rangle$, $\langle pad \rangle$, $\langle unk \rangle$
yordamchi tokenlar.

The round trip test - matnini encode qilob ID ga o'girib, sonda decode qilganda aynan asl matn qaytib kelishini tekshiruvchi assert test.

Data Splitting - datasetni train va valid (test) qismlarga ajratish. Data bo'lagini doimo sladd.

Tokenizerni 3 turli bor

↙	↓	↘
Character	Word	Subword (BPE)

Nega LLM larda Subword Tokenizerni ishlatiladi

Subwording - sozlarni foliq holatda yoki faqat harflar bo'yicha emas balki sozning ichidagi manoli des. tes uchraydigan qismlarga (token) bo'lib olish usuli. LLM larda bu lugat xarini normal sozlar va tokenlar soni o'rtasida yaxshi balans beradi.

BPE Merge Rules nima?

Byte pair encoding - tokenlarni yara holatda eng ko'p uchraydigan token juftliklarini bosqichma-bosqich birlashtiradi.

Merge rule - tokenlar organlan
birlashtirish qoidasi.

Byte level BPE nima?

Oddiy BPE sora yoki belgilarni birlashtirish mumkin. Byte-level BPE esa ma'nalik matnning bytalariga aylangan. Afzalroq istalgan unicode matnning qayta ishlay oladi.

Vocabulary size nima?

Bu - tokenlar bilan bog'liq umumiy tokenlar soni.

Special tokens - oddiy tokenlarda qo'shgan modelga maxsus rasmlar beradigan tokenlar mavjud.

BOs - beginning of sequence

EOS - end of sequence

PAD - sequence uzunligini tenglashtirish

UNK - tokenlar nomini token u-n ^{ishlatish} m-n

Round trip test - nima?

Bu tokenlarning encode-decode jarayonini tekshiruvchi test.

Fertility nima?

Fertility - bitta sora qancha nechta token bolib ketishini ko'rsatadi.

Compression - Tokenlar ma'nini nechta
token bilan ifodalaganini bilish uchun
bitta token qancha ma'nini ifodaladi.

Meta tokenlarola uint16 ishlatiladi

bu storage optimization masalasi
uint16 - unsigned 16-bit integers, bu 2 byte'ga
egallaydi, storage 2 barabar kamayadi.

.bin ga yozish nima?

.bin = binary fayl. Tokenlarni ma'nini sifatida
saglash o'rniga binary formatda
saglash mumkin chunki bin format
training pipeline ni qulay

Kodlash nima? Bu yerda 2 xil
encoding ma'nisida fahmida mumkin.

Tokenlar kontekstga ma'nini kodlashga
o'xshash tokenization/encoding.

Kayin token ID larini binary format
saglash/kodlash mumkin.

meta.json nima uchun kerak?

.bin faylda asosan token ID lar qoladi
lekin bu yerda bu tokenlar qaysi
Vocabularyga tegishli degan ma'lumot
berilmaydi. Shu sababli meta data
saxti qo'llanib meta - data haqida ma'lumot

Sequence packing - bir nechta qisqa
ma'nilarni bitta uzun training
sequence ga qo'llash.

Input/Target shift nima?

Bu neural language modelling asosiy
prinsipl. Model keyingi tokenni
qaytarib berish uchun
asosiy ma'lumot chunki L_{t-1} ni
qaytarib berish.