

LLM 2-oy 11-Dars Report

Serving & Readlines

Bo's tayyorlagan modelni ushga
yuklab berish.

uni 2 xil usuli bor

1- O'zini alohida qilib o'qish

2- Boshqa application/bu connect
qilish orqali

Sampling.py fayl bor infereni
ichida bu modelni ushga

yuklab berishga birlan
bucket sinab ko'rib diya o'qish

Yana bor kamoni model chiqarish
tokenlardan keyingi tokanni qanday
tanlashni boshlaydi

engine.py - Model + tokenlarni bor
maxta yuklaydi va generate qiladi

app.py - LLM ni FastAPI API bo'linishda
ishga tushiradi

Evaluation va Generation

Modelni baholab uning ishlash jara-
yonini tekshirish, Metriklar

Perplexity (PPL) / BLEU / ROUGE
va human evaluation

Evaluationning Asosiy 3 ta maqsadi

- Performansni measure qilish
- kuchli tamoni topish
- Modelni reallikdagi xarakat

Generation - bu usuldan kelgan savdalar olib tashlanib b-n shloa berib uni yana inson to'y shodigan qilib ishlash yangi jarayonni berish

Generationni bir nechta turli strategiyalar mavjud.

- Greedy decoding
- Top-k sampling
- Top-p sampling
- Temperature

matematik ushloshi tamonidan bir savdalar faqat qoladi

Xulosa: Generation - input berilgan, output signal chiqarilguncha bir jarayon

Deployment Artifacts

Biz asosiy dadigan fayl model.pt

Vercel - Vercel bu frontend va n reasit hub b-n o'ldi qoladi

Railway - backend tamoni uchun deploy qilindi

Vercel => Deployments qismida loyshan Deploy qilindi reasit

Environment Variable => bu yerda api keylar, parollar, lozmlar

shu yerdan beriladi.
Logs $\Rightarrow$ bu yerda loyihani
monitoring qilish funktsiyasi munosib.

Yaragani VS code da loyihani yaratish
 $\Rightarrow$ Git Hubga push qilindi $\Rightarrow$
Git Hubdan 2 tamonga push qilindi
1-si Vercelga Frontend uchun.

2-si Railwayga Backend uchun.
Hozircha Git Pretraining ni amalga
oshirish endi Posttraining oqimida
Git yaratgan LLM modelini
kuchaytirib reqlantaramiz.

Model Design - bu oqimda ham
kuchli parametrlarni fursat olamiz
vocab size, nindan qancha ishlatishni
belgilaymiz.