LLM 3-oy 6-Dars Report

Mening loyiham - kichik til modellarni o'rganish, ularni post-training usullari bilan moslashtirish va foydalani bilan suhbatlasha oladigan web-ilova orqali namoyish etishga mo'ljallangan loyiha.

Frontend - Vercelda
Backend - Renderda joylashtirilgan

Asosiy modelim = Qwen 2.5 - 0.5B.

Jarayon

User => chatga savol yozadi

⇓

Frontend Vercelda => HTML va JavaScript so'rovni API ga yuboradi.

⇓

Backend - Renderda => FASTAPI so'rovni qabul qilib qayta ishlaydi.

⇓

Qwen2.5-0.5B modeli kiritilgan matnga asoslanib, keyingi tokenlarni yaratadi.

SFT - Modelni namunaviy savol-javoblar orqali o'rgatish

LoRA - Model parametrlarining kichik qo'shimcha qismini o'rgatish orqali moslashtirish

QLoRA - Kvantlangan model yordamida xotira sarfini kamaytirib LoRA bilan o'qitish

DPO - Afzal javoblar va afzal bo'lmagan javoblar juftligi orqali modelni moslashtirish

LLM Post_Training - Qwen kabi katta til modellarini o'rgatish

SFT, LoRA, QLoRA, DPO usullari orqali moslashtirish tajribalarini bajarish, model natijalarini baholash va tayyor modelni FAST API backend hamda web-chat orqali namoyish etishga mo'ljallangan loyiha

LLM modellarining asosiy turlari

BaseModel – katta hajmdagi matnlar ustida pretraining qilingan model. Uning asosiy vazifasi – berilgan matndan keyin kelishi mumkin bo'lgan tokenlarni bashorat qilish.

Instruct Model – foydalanuvchining ko'rsatmalarini tushunish va ularga mos javob berish uchun qo'shimcha o'qitilgan model.

Chat model – suhbatlar formatida ishlashga moslashgan model. Odatda foydalanuvchi va

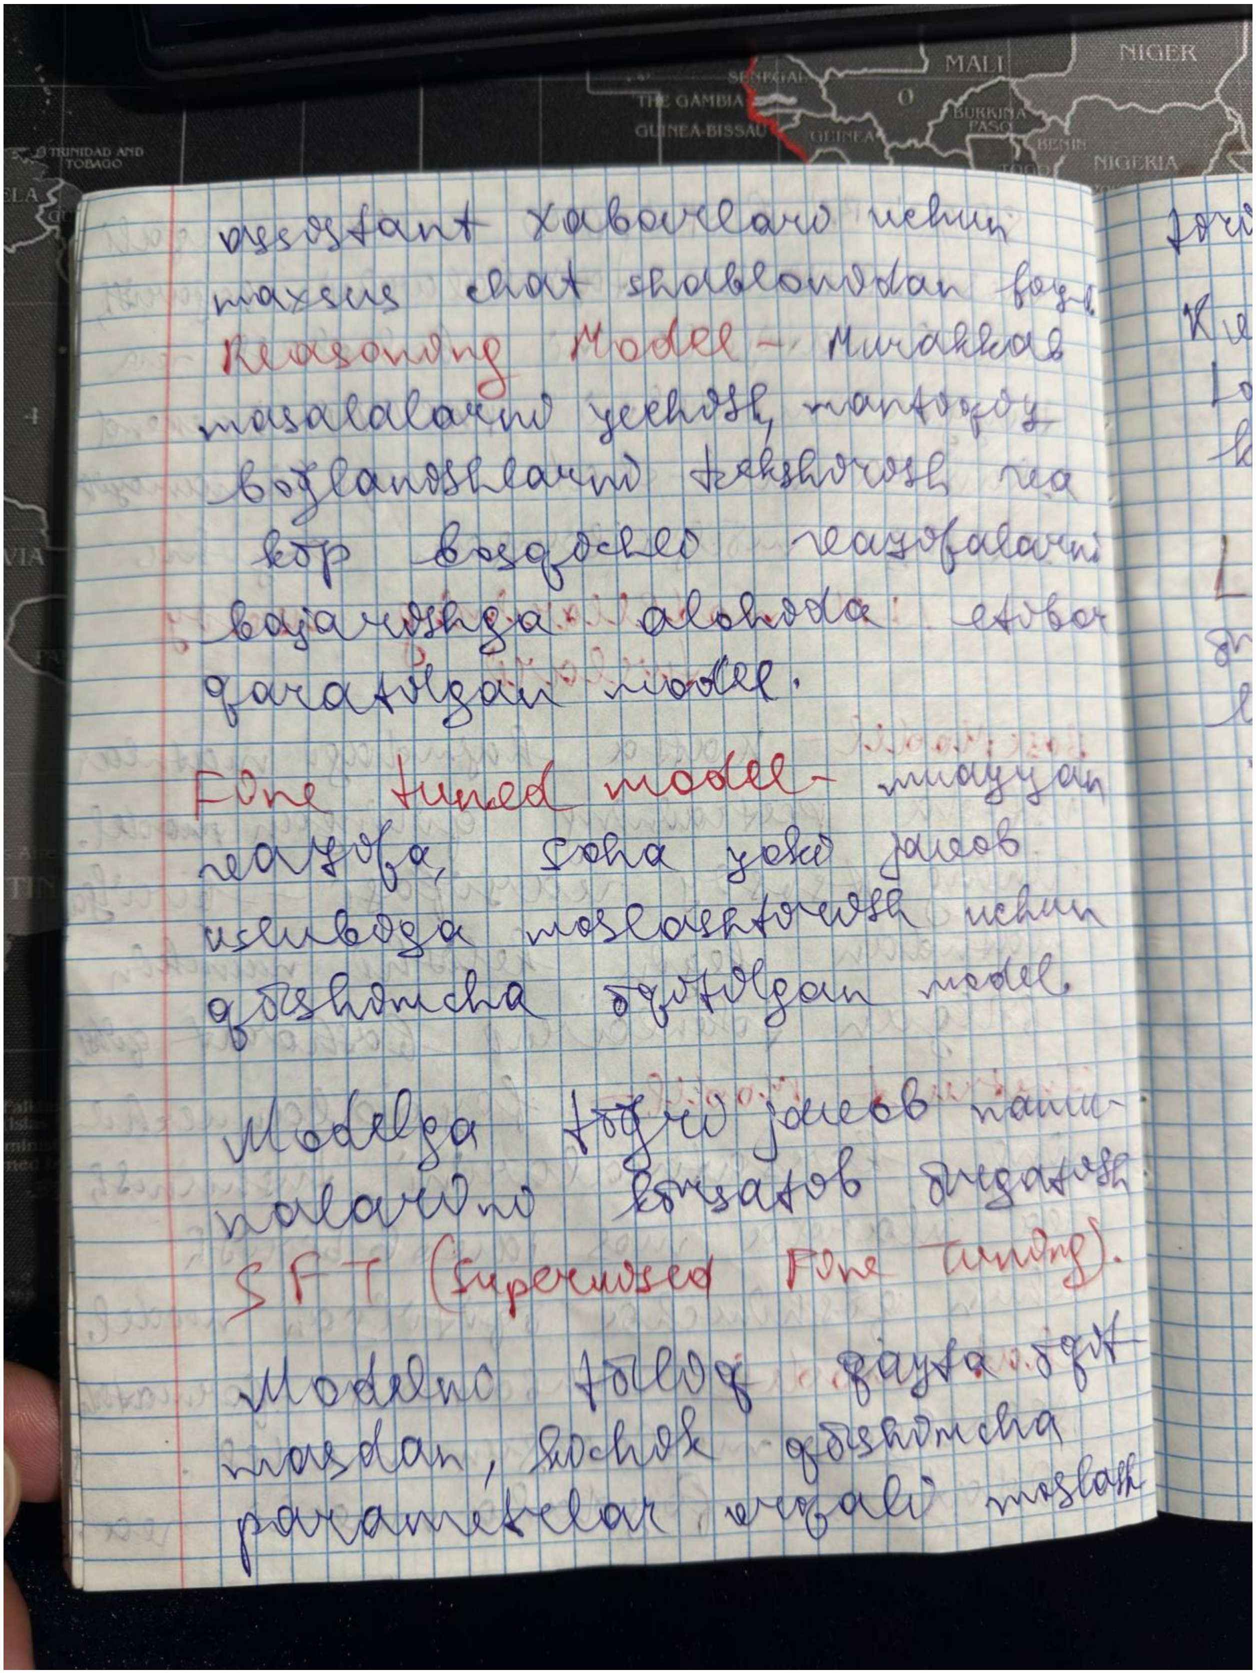

assistant xabarlari uchun maxsus chat shablonidan foyd.

Reasoning Model – Murakkab masalalarni yechish, mantiqiy bog'lanishlarni tekshirish va ko'p bosqichli vazifalarni bajarishga alohida e'tibor qaratilgan model.

Fine tuned model – muayyan vazifa, soha yoki javob uslubiga moslashtirish uchun qo'shimcha o'qitilgan model.

Modelga to'g'ri javob namunalarini ko'rsatib o'rgatish SFT (Supervised Fine tuning).

Modelni to'liq qayta o'qitmasdan, kichik qo'shimcha parametrlar orqali moslash torish – LoRA

Kvantlangan model asosida LoRA bilan xotira sarfini kamaytirib o'qitish – QLoRA

LoRA – qaysi parametrlarni o'rgatish usuli, 4-bit parametrlarni qanday ixcham qilish usuli, QLoRA – ikkalasini birlashti